

# 实验2 MapReduce实验报告

姓名：滕子鉴

学号：231275015

实验时间：2025年10月

## 实验2 MapReduce实验报告

### 一、实验目的

### 二、实验环境

### 三、任务一：消费行为统计

#### 3.1 任务目标

#### 3.2 设计思路

核心逻辑伪代码

#### 3.3 核心代码实现

#### 3.4 运行结果

线下数据结果（部分）

线上数据结果（部分）

#### 3.5 可能的改进

### 四、任务二：商家周边活跃顾客数量统计

#### 4.1 任务目标

#### 4.2 设计思路

核心逻辑伪代码

#### 4.3 核心代码实现

#### 4.4 运行结果（部分）

#### 4.5 可能的改进

### 五、任务三：优惠券使用时间统计

#### 5.1 任务目标

#### 5.2 设计思路

第一阶段伪代码

第二阶段伪代码

#### 5.3 核心代码实现

#### 5.4 运行结果

#### 5.5 可能的改进

### 六、任务四：优惠券使用影响因素分析

#### 6.1 任务目标

#### 6.2 分析一：折扣率对使用率的影响

设计思路伪代码

核心代码实现

运行结果

结果分析

#### 6.3 分析二：领取时间对使用率的影响

设计思路伪代码

核心代码实现

运行结果

结果分析

#### 6.4 分析三：商家发券量对使用率的影响

设计思路

第一阶段伪代码

第二阶段伪代码

核心代码实现

运行结果

## 一、实验目的

1. 掌握MapReduce编程模型的基本原理
2. 学习使用Hadoop平台进行分布式数据处理
3. 通过真实数据分析优惠券使用规律

## 二、实验环境

- **操作系统:** Ubuntu 22.04 LTS
- **Hadoop版本:** Hadoop 3.4.0
- **Java版本:** OpenJDK 1.8
- **运行模式:** 伪分布式模式
- **开发工具:** 文本编辑器 + 命令行编译

## 三、任务一：消费行为统计

### 3.1 任务目标

统计每个商家的优惠券使用情况，分为三种类型：

1. **负样本数:** 领取优惠券但未使用
2. **普通消费数:** 未领取优惠券直接消费
3. **正样本数:** 领取优惠券并使用

**输出格式:** <Merchant\_id> TAB <负样本数> TAB <普通消费数> TAB <正样本数>

### 3.2 设计思路

#### 核心逻辑伪代码

**Mapper伪代码:**

```

1 function Map(key, line):
2     if line是表头:
3         return
4
5     解析line得到字段: Merchant_id, Coupon_id, Date_received, Date
6
7     // 根据文件名判断是线上还是线下数据
8     if 是线上数据:
9         if Action == 1 且 Coupon_id == null:
10             // 普通消费
11             emit(Merchant_id, "0,1,0")
12         else if Action == 2 且 Coupon_id != null:
13             if Date != null:

```

```

14         // 领取并使用
15         emit(Merchant_id, "0,0,1")
16     else:
17         // 领取未使用
18         emit(Merchant_id, "1,0,0")
19     else: // 线下数据
20         if Coupon_id != null 且 Date_received != null:
21             if Date != null:
22                 // 领取并使用
23                 emit(Merchant_id, "0,0,1")
24             else:
25                 // 领取未使用
26                 emit(Merchant_id, "1,0,0")
27         else if Coupon_id == null 且 Date != null:
28             // 普通消费
29             emit(Merchant_id, "0,1,0")

```

**Reducer伪代码:**

```

1 function Reduce(Merchant_id, values):
2     negative_count = 0    // 负样本
3     normal_count = 0      // 普通消费
4     positive_count = 0    // 正样本
5
6     for each value in values:
7         解析value得到三个计数
8         negative_count += value的第一个数
9         normal_count += value的第二个数
10        positive_count += value的第三个数
11
12    emit(Merchant_id, negative_count + "\t" + normal_count + "\t" +
13        positive_count)

```

### 3.3 核心代码实现

**Mapper核心代码:**

```

1 @Override
2 protected void setup(Context context) throws IOException,
3 InterruptedException {
3     FileSplit fileSplit = (FileSplit) context.getInputSplit();
4     String fileName = fileSplit.getPath().getName();
5     isonlineData = fileName.contains("online");
6 }
7
8 @Override
9 protected void map(LongWritable key, Text value, Context context) {
10     // 跳过表头
11     if (key.get() == 0) return;
12
13     String[] fields = line.split(",");
14
15     if (isonlineData) {
16         // 线上数据处理逻辑

```

```

17     string action = fields[2].trim();
18     if ("1".equals(action) && "null".equals(couponId)) {
19         valueOut.set("0,1,0"); // 普通消费
20     } else if ("2".equals(action) && !"null".equals(couponId)) {
21         if (!"null".equals(date)) {
22             valueOut.set("0,0,1"); // 使用
23         } else {
24             valueOut.set("1,0,0"); // 未使用
25         }
26     }
27 } else {
28     // 线下数据处理逻辑
29     if (!"null".equals(couponId) && !"null".equals(dateReceived)) {
30         if (!"null".equals(date)) {
31             valueOut.set("0,0,1");
32         } else {
33             valueOut.set("1,0,0");
34         }
35     } else if ("null".equals(couponId) && !"null".equals(date)) {
36         valueOut.set("0,1,0");
37     }
38 }
39
40 context.write(merchantId, valueout);
41 }

```

Reducer核心代码：

```

1 @Override
2 protected void reduce(Text key, Iterable<Text> values, Context context) {
3     int negativeCount = 0, normalCount = 0, positiveCount = 0;
4
5     for (Text value : values) {
6         String[] counts = value.toString().split(",");
7         negativeCount += Integer.parseInt(counts[0]);
8         normalCount += Integer.parseInt(counts[1]);
9         positiveCount += Integer.parseInt(counts[2]);
10    }
11
12    result.set(negativeCount + "\t" + normalCount + "\t" + positiveCount);
13    context.write(key, result);
14 }

```

## 3.4 运行结果

### 线下数据结果（部分）

	商家ID	负样本数	普通消费数	正样本数
1				

≡ task1\_offline\_result.txt

1	1	0	12	0
2	100	1	1	0
3	1000		0	5
4	1001		7	20
5	1002		5	8
6	1003		0	3
7	1004		82	281
8	1005		30	19
9	1007		3	22
10	1008		0	11
11	1009		0	1
12	101	0	4	0
13	1010		3	10
14	1011		63	59
15	1013		29	64
16	1015		19	16
17	1016		10	5
18	1017		8	9
19	1018		4	6
20	1019		0	4
21	102	1	3	0
22	1020		0	3
23	1021		0	5
24	1022		0	7
25	1023		4	41
26	1024		0	14
27	1025		10	6
28	1026		1	17
29	1027		0	13
30	1028		4	24
31	1029		2	0
32	103	0	4	0
33	1030		0	11
34	1031		2	2
35	1032		2	0
36	1033		0	0

37	<b>1034</b>	8	14	0	
38	<b>1035</b>	33	3	1	
39	<b>1036</b>	18	62	1	
40	<b>1037</b>	21	54	9	

### 线上数据结果 (部分)

1 | 商家ID 负样本数 普通消费数 正样本数

task1\_online\_result.txt

1	10001	118	53	11
2	10002	0	6	0
3	10003	0	1	0
4	10004	0	3	0
5	10005	0	3	0
6	10006	95	2	2
7	10007	0	172	0
8	10008	0	36	0
9	10009	0	12	0
10	10010	0	1	0
11	10011	0	4	0
12	10012	13	2	1
13	10014	31	14	0
14	10100	0	4	0
15	10102	5	2	2
16	10103	0	28	0
17	10104	0	4	0
18	10105	0	5	0
19	10106	0	19	0
20	10107	4	9	0
21	10108	0	1	0
22	10109	0	2	0
23	10110	2	11	1
24	10111	11	2	3
25	10112	13	3	19
26	10113	0	7	0
27	10114	5	150	0
28	10201	0	4	0
29	10202	0	2	0
30	10203	0	5	1
31	10205	0	5	0
32	10206	0	11	0
33	10207	0	7	0
34	10208	0	1	0
35	10209	0	16	0
36	10210	13	0	2

	37	38	39	40	41	42
	10211	10212	10213	10214	10215	10216
	29	6	0	0	15	15
	8	11	5	10	0	0
	1	0	0	0	0	0

### 3.5 可能的改进

1. 统计不同时间段的消费行为变化
2. 结合User\_id分析不同用户群体的行为差异

## 四、任务二：商家周边活跃顾客数量统计

### 4.1 任务目标

统计每个商家与周边消费者的距离分布，给出不同距离的活跃消费者人数。

**输出格式：** <Merchant\_id> TAB Distance=<距离>:<消费者人数>

### 4.2 设计思路

#### 核心逻辑伪代码

**Mapper伪代码：**

```

1 function Map(key, line):
2     if line是表头:
3         return
4
5     解析line得到: User_id, Merchant_id, Distance
6
7     if Distance == null:
8         Distance = "null"
9
10    // 组合key: Merchant_id,Distance
11    composite_key = Merchant_id + "," + Distance
12
13    emit(composite_key, User_id)

```

**Reducer伪代码：**

```

1 function Reduce(composite_key, user_ids):
2     // composite_key格式: Merchant_id,Distance
3     // 解析得到: Merchant_id, Distance
4
5     // 使用HashSet去重统计不同用户
6     unique_users = HashSet()
7     for each user_id in user_ids:
8         unique_users.add(user_id)
9
10    user_count = unique_users.size()
11
12    emit(Merchant_id, "Distance=" + Distance + ":" + user_count)

```

## 4.3 核心代码实现

Mapper核心代码：

```

1 @Override
2 protected void map(LongWritable key, Text value, Context context) {
3     String[] fields = line.split(",");
4
5     String userId = fields[0].trim();
6     String merchantId = fields[1].trim();
7     String distance = fields[4].trim();
8
9     // 处理null值
10    if ("null".equals(distance) || distance.isEmpty()) {
11        distance = "null";
12    }
13
14    // 组合键: Merchant_id,Distance
15    outputKey.set(merchantId + "," + distance);
16    outputValue.set(userId);
17
18    context.write(outputKey, outputValue);
19 }

```

Reducer核心代码：

```

1 @Override
2 protected void reduce(Text key, Iterable<Text> values, Context context) {
3     // 使用HashSet去重
4     HashSet<String> uniqueUsers = new HashSet<>();
5
6     for (Text value : values) {
7         uniqueUsers.add(value.toString());
8     }
9
10    // 解析key
11    String[] keyParts = key.toString().split(",");
12    String merchantId = keyParts[0];
13    String distance = keyParts[1];
14
15    outputKey.set(merchantId);

```

```
16     outputValue.set("Distance=" + distance + ":" + uniqueUsers.size());  
17  
18     context.write(outputKey, outputValue);  
19 }
```

## 4.4 运行结果 (部分)

1 | 商家ID 距离分布

task2\_result.txt

1	1	Distance=0:2
2	100	Distance=1:1
3	1000	Distance=0:1
4	1001	Distance=0:4
5	1001	Distance=10:2
6	1001	Distance=3:1
7	1001	Distance=5:1
8	1001	Distance=7:1
9	1001	Distance=null:2
10	1002	Distance=0:3
11	1003	Distance=0:1
12	1003	Distance=1:1
13	1004	Distance=0:30
14	1004	Distance=1:5
15	1004	Distance=10:1
16	1004	Distance=2:2
17	1004	Distance=5:2
18	1004	Distance=7:2
19	1004	Distance=null:3
20	1005	Distance=0:9
21	1005	Distance=1:4
22	1005	Distance=10:3
23	1005	Distance=2:3
24	1005	Distance=3:1
25	1005	Distance=4:1
26	1005	Distance=5:1
27	1005	Distance=null:9
28	1007	Distance=0:4
29	1007	Distance=1:1
30	1007	Distance=10:5
31	1007	Distance=3:4
32	1007	Distance=4:2
33	1007	Distance=5:1
34	1007	Distance=8:1
35	1007	Distance=9:1
36	1008	Distance=1:1

```
36    1008      Distance=1:1
37    1008      Distance=3:1
38    1009      Distance=6:1
39    101       Distance=10:2
40    101       Distance=5:1
```

## 4.5 可能的改进

1. 生成商家周边消费者分布热力图
2. 结合时间维度分析不同时段的距离分布变化

# 五、任务三：优惠券使用时间统计

## 5.1 任务目标

统计每种优惠券的使用次数，对于使用次数大于总使用次数1%的优惠券，计算从领取到使用的平均间隔天数并排序。

**输出格式：** <Coupon\_id> TAB <平均消费间隔天数>

## 5.2 设计思路

本任务需要**两阶段MapReduce**：

- **第一阶段**：统计每个优惠券的使用次数和总间隔天数
- **第二阶段**：过滤使用次数>1%阈值的优惠券，计算平均间隔并排序

### 第一阶段伪代码

**Mapper1伪代码：**

```
1 function Map1(key, line):
2     if line是表头:
3         return
4
5     解析line得到: Coupon_id, Date_received, Date
6
7     if Coupon_id == null 或 Date == null 或 Date_received == null:
8         return // 只统计被使用的优惠券
9
10    // 计算日期间隔
11    interval_days = Date - Date_received
12
13    emit(Coupon_id, interval_days)
```

**Reducer1伪代码：**

```

1 function Reduce1(Coupon_id, interval_days_list):
2     count = 0
3     total_days = 0
4
5     for each interval in interval_days_list:
6         count += 1
7         total_days += interval
8
9     emit(Coupon_id, count + "," + total_days)

```

## 第二阶段伪代码

Mapper2伪代码：

```

1 function Setup():
2     // 读取第一阶段输出，计算总使用次数
3     total_usage_count = 0
4     for each line in stage1_output:
5         解析得到count
6         total_usage_count += count
7
8     threshold = total_usage_count * 0.01
9
10 function Map2(key, line):
11     解析line得到: Coupon_id, count, total_days
12
13     if count > threshold:
14         avg_days = total_days / count
15
16     // 使用avg_days作为key实现排序
17     emit(格式化的avg_days, Coupon_id + "\t" + avg_days)

```

Reducer2伪代码：

```

1 function Reduce2(avg_days, coupon_info_list):
2     // 直接输出，已经按avg_days排序
3     for each info in coupon_info_list:
4         解析得到: Coupon_id, avg_days
5         emit(Coupon_id, avg_days)

```

## 5.3 核心代码实现

第一阶段Mapper核心代码：

```

1 private SimpleDateFormat dateFormat = new SimpleDateFormat("yyyyMMdd");
2
3 @Override
4 protected void map(LongWritable key, Text value, Context context) {
5     String[] fields = line.split(",");
6
7     String coupon = fields[2].trim();
8     String dateReceived = fields[5].trim();
9     String date = fields[6].trim();

```

```

10
11     // 只统计被使用的优惠券
12     if ("null".equals(coupon) || "null".equals(date) ||
13         "null".equals(dateReceived)) {
14         return;
15     }
16
17     // 计算日期间隔
18     Date receivedDate = dateFormat.parse(dateReceived);
19     Date usedDate = dateFormat.parse(date);
20     long diffInMillis = usedDate.getTime() - receivedDate.getTime();
21     long diffInDays = diffInMillis / (1000 * 60 * 60 * 24);
22
23     couponId.set(coupon);
24     outputValue.set(string.valueOf(diffInDays));
25     context.write(couponId, outputValue);
26 }
```

## 第二阶段Mapper核心代码：

```

1 @Override
2 protected void setup(Context context) throws IOException {
3     // 读取第一阶段输出
4     Configuration conf = context.getConfiguration();
5     String tempPath = conf.get("temp.output.path");
6     FileSystem fs = FileSystem.get(conf);
7
8     BufferedReader br = new BufferedReader(
9         new InputStreamReader(fs.open(new Path(tempPath + "/part-r-00000"))))
10    );
11
12    long totalUsageCount = 0;
13    String line;
14    while ((line = br.readLine()) != null) {
15        String[] parts = line.split("\t");
16        String[] countAndTotal = parts[1].split(",");
17        totalUsageCount += Long.parseLong(countAndTotal[0]);
18    }
19    br.close();
20
21    threshold = totalUsageCount * 0.01;
22 }
23
24 @Override
25 protected void map(LongWritable key, Text value, Context context) {
26     String[] parts = line.split("\t");
27     String couponId = parts[0];
28     String[] countAndTotal = parts[1].split(",");
29
30     long count = Long.parseLong(countAndTotal[0]);
31     long totalDays = Long.parseLong(countAndTotal[1]);
32
33     if (count > threshold) {
34         double avgDays = (double) totalDays / count;
35     }
36 }
```

```
36     // 格式化用于排序
37     String sortKey = String.format("%010.2f", avgDays);
38     Text outputKey = new Text(sortKey);
39     Text outputValue = new Text(couponId + "\t" +
40                               String.format("%.2f", avgDays));
41
42     context.write(outputKey, outputValue);
43 }
44 }
```

## 5.4 运行结果

1 | 优惠券ID 平均间隔天数

≡ task3_result.txt		
1	7751	11.22
2	111	11.24
3	9776	12.30
4	10323	4.96
5	5686	4.97
6	12034	8.54
7	11539	8.65
8	4773	8.79
9	2418	9.18

## 5.5 可能的改进

1. 可以尝试0.5%或0.1%的阈值，获取更多样本
2. 统计不同间隔区间的优惠券数量分布
3. 除了平均值，还可以统计中位数

# 六、任务四：优惠券使用影响因素分析

## 6.1 任务目标

自行选取可能影响优惠券使用行为的因素，通过MapReduce统计分析这些因素对优惠券使用率的影响。

我选择分析三个因素：

1. 打折率对使用率的影响
2. 领取时间（周末vs工作日）对使用率的影响
3. 商家发券量对使用率的影响

## 6.2 分析一：折扣率对使用率的影响

### 设计思路伪代码

Mapper伪代码：

```
1 function Map(key, line):
2     解析line得到: Coupon_id, Discount_rate, Date_received, Date
3
4     if Coupon_id == null 或 Date_received == null:
5         return
6
7     // 解析折扣率并分类
8     if Discount_rate包含":":
9         // 满减类型: x:y
10        actual_rate = (x - y) / x
11    else:
12        // 直接折扣
13        actual_rate = Discount_rate
14
15    // 分类
16    if actual_rate >= 0.9:
17        category = "0.9-1.0_低折扣"
18    else if actual_rate >= 0.8:
19        category = "0.8-0.9_中低折扣"
20    else if actual_rate >= 0.7:
21        category = "0.7-0.8_中等折扣"
22    else if actual_rate >= 0.5:
23        category = "0.5-0.7_中高折扣"
24    else:
25        category = "0.0-0.5_高折扣"
26
27    if Date != null:
28        status = "used"
29    else:
30        status = "unused"
31
32    emit(category, status)
```

Reducer伪代码：

```
1 function Reduce(category, status_list):
2     used_count = 0
3     unused_count = 0
4
5     for each status in status_list:
6         if status == "used":
7             used_count += 1
8         else:
9             unused_count += 1
10
11    total = used_count + unused_count
12    usage_rate = (used_count / total) * 100
13
14    emit(category, "领取：" + total + "， 使用：" + used_count + "
```

```
15 |     ", 使用率:" + usage_rate + "%")
```

## 核心代码实现

折扣率解析函数：

```
1 private String parseDiscountCategory(String discountRate) {
2     if ("null".equals(discountRate) || discountRate.isEmpty()) {
3         return null;
4     }
5
6     try {
7         if (discountRate.contains(":")) {
8             // 满减类型: x:y
9             String[] parts = discountRate.split(":");
10            double full = Double.parseDouble(parts[0]);
11            double minus = Double.parseDouble(parts[1]);
12            double actualRate = (full - minus) / full;
13            return categorizeRate(actualRate);
14        } else {
15            // 直接折扣
16            double rate = Double.parseDouble(discountRate);
17            return categorizeRate(rate);
18        }
19    } catch (NumberFormatException e) {
20        return null;
21    }
22 }
23
24 private String categorizeRate(double rate) {
25     if (rate >= 0.9) return "0.9-1.0_低折扣";
26     else if (rate >= 0.8) return "0.8-0.9_中低折扣";
27     else if (rate >= 0.7) return "0.7-0.8_中等折扣";
28     else if (rate >= 0.5) return "0.5-0.7_中高折扣";
29     else return "0.0-0.5_高折扣";
30 }
```

## 运行结果

```
1 | 折扣类别          统计结果
```

```
≡ task4_discount_result.txt
```

```
1 0.0-0.5_高折扣 领取:59, 使用:3, 使用率:5.08%
2 0.5-0.7_中高折扣 领取:16100, 使用:1995, 使用率:12.39%
3 0.7-0.8_中等折扣 领取:54275, 使用:7434, 使用率:13.70%
4 0.8-0.9_中低折扣 领取:3867, 使用:800, 使用率:20.69%
5 0.9-1.0_低折扣 领取:58292, 使用:9174, 使用率:15.74%
```

## 结果分析

关键发现：

1. 中低折扣 (0.8-0.9) 使用率最高：达到20.69%
2. 并非折扣越大使用率越高：高折扣(0.0-0.5)使用率仅5.08%
3. U型曲线特征：中等力度折扣使用率反而不如中低和低折扣

可能原因：

- **高折扣门槛高**：通常需要满足较高的消费金额
- **信任度问题**：过高的折扣可能让用户怀疑产品质量
- **中等折扣最优**：0.8-0.9的折扣既有吸引力又不会让用户怀疑

## 6.3 分析二：领取时间对使用率的影响

设计思路伪代码

Mapper伪代码：

```
1 function Map(key, line):  
2     解析line得到: Coupon_id, Date_received, Date  
3  
4     if Coupon_id == null 或 Date_received == null:  
5         return  
6  
7     // 解析日期，判断星期几  
8     date_obj = parse_date(Date_received)  
9     day_of_week = get_day_of_week(date_obj)  
10  
11    if day_of_week是周六或周日:  
12        day_type = "周末"  
13    else:  
14        day_type = "工作日"  
15  
16    if Date != null:  
17        status = "used"  
18    else:  
19        status = "unused"  
20  
21    emit(day_type, status)
```

Reducer伪代码：

```
1 function Reduce(day_type, status_list):  
2     // 与分析一相同，统计使用率  
3     ...
```

## 核心代码实现

```
1 private SimpleDateFormat dateFormat = new SimpleDateFormat("yyyyMMdd");
2
3 @Override
4 protected void map(LongWritable key, Text value, Context context) {
5     String[] fields = line.split(",");
6
7     String dateReceived = fields[5].trim();
8
9     // 解析日期
10    Date receivedDate = dateFormat.parse(dateReceived);
11    Calendar cal = calendar.getInstance();
12    cal.setTime(receivedDate);
13
14    int dayofweek = cal.get(calendar.DAY_OF_WEEK);
15
16    if (dayofweek == Calendar.SATURDAY || dayofweek == Calendar.SUNDAY) {
17        dayType.set("周末");
18    } else {
19        dayType.set("工作日");
20    }
21
22    // 判断使用状态
23    if (!"null".equals(date)) {
24        usageStatus.set("used");
25    } else {
26        usageStatus.set("unused");
27    }
28
29    context.write(dayType, usageStatus);
30 }
```

## 运行结果

1 | 领取时间      统计结果

```
☰ task4_weekday_result.txt
1 周末    领取:211411, 使用:13437, 使用率:6.36%
2 工作日   领取:418413, 使用:31529, 使用率:7.54%
```

## 结果分析

关键发现:

1. **工作日使用率更高:** 7.54% vs 6.36%, 差异约1.2个百分点
2. **工作日领取量更大:** 约为周末的2倍

可能原因:

- 工作日领取的用户可能有明确的购买计划
- 周末浏览时随手领取, 实际使用意愿较弱

- 工作日时间有限，领券后更倾向于快速使用

## 6.4 分析三：商家发券量对使用率的影响

### 设计思路

本分析需要两阶段MapReduce：

- 第一阶段：统计每个商家的发券量和使用量
- 第二阶段：按发券量分类，计算各类商家的整体使用率

### 第一阶段伪代码

Mapper1伪代码：

```
1 function Map1(key, line):  
2     解析line得到: Merchant_id, Coupon_id, Date_received, Date  
3  
4     if Coupon_id == null 或 Date_received == null:  
5         return  
6  
7     if Date != null:  
8         emit(Merchant_id, "1") // 已使用  
9     else:  
10        emit(Merchant_id, "0") // 未使用
```

Reducer1伪代码：

```
1 function Reduce1(Merchant_id, status_list):  
2     total_count = 0  
3     used_count = 0  
4  
5     for each status in status_list:  
6         total_count += 1  
7         if status == "1":  
8             used_count += 1  
9  
10    emit(Merchant_id, total_count + "," + used_count)
```

### 第二阶段伪代码

Mapper2伪代码：

```
1 function Map2(key, line):  
2     解析line得到: Merchant_id, total_count, used_count  
3  
4     // 根据发券量分类  
5     if total_count >= 1000:  
6         category = "高活跃商家(>=1000券)"  
7     else if total_count >= 500:  
8         category = "中高活跃商家(500-999券)"  
9     else if total_count >= 100:  
10        category = "中等活跃商家(100-499券)"
```

```

11     else if total_count >= 50:
12         category = "中低活跃商家(50-99券)"
13     else:
14         category = "低活跃商家(<50券)"
15
16     emit(category, total_count + "," + used_count)

```

### Reducer2伪代码:

```

1 function Reduce2(category, count_list):
2     total_coupons = 0
3     used_coupons = 0
4     merchant_count = 0
5
6     for each counts in count_list:
7         解析得到: total, used
8         total_coupons += total
9         used_coupons += used
10        merchant_count += 1
11
12        usage_rate = (used_coupons / total_coupons) * 100
13        avg_coupons = total_coupons / merchant_count
14
15        emit(category, "商家数:" + merchant_count +
16                  ", 总发券:" + total_coupons +
17                  ", 总使用:" + used_coupons +
18                  ", 使用率:" + usage_rate + "%" +
19                  ", 平均发券:" + avg_coupons)

```

## 核心代码实现

### 第二阶段Mapper核心代码:

```

1 private String categorizeMerchant(int couponCount) {
2     if (couponCount >= 1000) {
3         return "高活跃商家(>=1000券)";
4     } else if (couponCount >= 500) {
5         return "中高活跃商家(500-999券)";
6     } else if (couponCount >= 100) {
7         return "中等活跃商家(100-499券)";
8     } else if (couponCount >= 50) {
9         return "中低活跃商家(50-99券)";
10    } else {
11        return "低活跃商家(<50券)";
12    }
13 }
14
15 @Override
16 protected void map(LongWritable key, Text value, Context context) {
17     String[] parts = line.split("\t");
18     String[] counts = parts[1].split(",");
19
20     int totalCount = Integer.parseInt(counts[0]);
21     int usedCount = Integer.parseInt(counts[1]);
22

```

```

23     String cat = categorizeMerchant(totalCount);
24     category.set(cat);
25     info.set(totalCount + "," + usedCount);
26
27     context.write(category, info);
28 }

```

## 第二阶段Reducer核心代码：

```

1  @Override
2  protected void reduce(Text key, Iterable<Text> values, Context context) {
3      long totalCoupons = 0, usedCoupons = 0;
4      int merchantCount = 0;
5
6      for (Text value : values) {
7          String[] counts = value.toString().split(",");
8          totalCoupons += Long.parseLong(counts[0]);
9          usedCoupons += Long.parseLong(counts[1]);
10         merchantCount++;
11     }
12
13     double usageRate = totalCoupons > 0 ?
14         (double) usedCoupons / totalCoupons * 100 : 0;
15     double avgCoupons = merchantCount > 0 ?
16         (double) totalCoupons / merchantCount : 0;
17
18     result.set(String.format(
19         "商家数:%d, 总发券:%d, 总使用:%d, 使用率:%.2f%%, 平均发券:%.1f",
20         merchantCount, totalCoupons, usedCoupons, usageRate, avgCoupons
21     ));
22
23     context.write(key, result);
24 }

```

## 运行结果

1 | 商家活跃度分类                   统计结果

```

task4_merchant_result.txt
1 中低活跃商家(50-99券) 商家数:262, 总发券:17872, 总使用:2959, 使用率:16.56%, 平均发券:68.2
2 中等活跃商家(100-499券) 商家数:188, 总发券:38831, 总使用:5480, 使用率:14.11%, 平均发券:206.5
3 中高活跃商家(500-999券) 商家数:33, 总发券:24378, 总使用:3567, 使用率:14.63%, 平均发券:738.7
4 低活跃商家(<50券) 商家数:4791, 总发券:45428, 总使用:7944, 使用率:17.49%, 平均发券:9.5
5 高活跃商家(>=1000券) 商家数:73, 总发券:503315, 总使用:25016, 使用率:4.97%, 平均发券:6894.7

```

## 结果分析

### 1. 发券数量与商家数

- 低活跃商家占据绝对多数 (4791)，体现平台长尾结构。
- 高活跃商家数量稀少 (73)，但发券量巨大。

呈现典型的长尾分布结构：少数商家贡献主要资源投放。

### 2. 使用率对比

- 低活跃商家使用率最高：17.49%

- 中低活跃次之：16.56%
  - 中等 / 中高活跃相对接近： $\approx$ 14%
  - 高活跃商家最低：仅 4.97%
- 表明随着发券规模上升，用户边际反应迅速下降。

### 3. 平均发券差异显著

- 低活跃商家仅 9.5 张/家，但利用率较好
  - 高活跃商家平均 6894.7 张/家，存在明显过度投放迹象
- 反映高活跃商家在粗放式营销中可能遭遇效率瓶颈。
- 

## 现象解释

### (1) 高活跃商家使用率低

- 发券过多导致用户资格泛化、缺乏稀缺性
- 店铺本身用户池有限

这属于供给过剩导致的转化率下滑。

### (2) 低活跃商家使用率高

- 用户更稀缺的优惠券有“珍惜感”
- 场景更明确、定位更明确
- 发券数量有限，能够精确触达忠实的顾客

### (3) 中段发券区间表现稳定

50-999 券区间商家表现较为均衡：

- 使用率  $\sim$ 14-16%
  - 增长较为平稳
- 

## 6.5 任务四可能的改进之处

### 1. 考虑多因素交叉分析：

- 分析折扣率+领取时间的组合效果
- 分析商家规模+折扣率的交互影响

### 2. 可以考虑机器学习：

- 使用逻辑回归预测优惠券使用概率
- 特征工程：提取更多特征（用户活跃度、历史使用率等）

### 3. 考虑加入时间序列分析：

- 分析不同月份、季节的使用率变化
- 研究节假日效应